Universidad Veracruzana

Facultad de Estadística e Informática

Predicción de síntomas depresivos en adultos mayores mexicanos mediante regresión logística múltiple

E.E: Metodología de la Investigación

Docente: Lorena López Lozada

Integrantes:

Cristian Axel Izquierdo López

Laura Yoselin Tonil De La Luz

23 de Septiembre de 2026

"Lis de Veracruz: Arte, Ciencia, Luz"

Resumen

El presente estudio tuvo como objetivo desarrollar un modelo de regresión logística múltiple para analizar y estimar la probabilidad de presentar depresión, medida mediante la escala CES-D, en adultos mayores mexicanos a partir de información de la Evaluación Cognitiva de ENASEM 2021. El procedimiento se organizó de acuerdo con la metodología CRISP-DM, considerando la comprensión del problema, comprensión de los datos, preparación, modelado, evaluación y una propuesta de despliegue. Se partió de 3,575 registros y 12 variables seleccionadas, de las cuales 11 fueron utilizadas como predictores y una como variable respuesta. Después de la limpieza se obtuvieron 3,418 casos completos, eliminándose 157 registros, equivalentes al 4.39% del conjunto original.

La variable respuesta quedó definida de forma binaria como ausencia o presencia de depresión. El conjunto analítico se dividió de manera estratificada en 70% para entrenamiento y 30% para prueba, con 2,392 y 1,026 observaciones, respectivamente. El modelo se estimó mediante un Modelo Lineal Generalizado con familia binomial y función de enlace logit. El ajuste presentó un pseudo R^2 de Cox-Snell de 0.2606. Entre los predictores con asociación estadísticamente significativa se encontraron el sexo, algunas categorías de dificultad en actividades de la vida diaria, aislamiento, sentirse ignorado, falta de compañía y nivel de estrés percibido.

En la evaluación, la prueba de Hosmer-Lemeshow presentó un p-valor de 0.2182, mientras que el área bajo la curva ROC obtenida sobre el conjunto de prueba fue de 0.8329. Estos resultados muestran que el modelo logró discriminar de manera adecuada entre los dos estados de la variable respuesta. No obstante, el diagnóstico de multicolinealidad mostró valores de VIF de 8.67 y 8.66 para dos categorías de percepción de memoria, por lo que este aspecto debe considerarse al interpretar el modelo.

Palabras clave: *CRISP-DM, regresión logística, depresión, CES-D, ENASEM, adultos mayores.*

Introducción

El análisis de la depresión en adultos mayores constituye un problema de interés para el estudio de las condiciones sociales, funcionales y cognitivas de esta población. Además de la presencia de síntomas depresivos, variables como la edad, el sexo, la funcionalidad para realizar actividades cotidianas, la percepción de la memoria, el aislamiento social, la percepción de ser ignorado, la falta de compañía y el estrés pueden aportar información para comprender las diferencias observadas en la variable de respuesta.

En este contexto, los modelos de regresión logística permiten estudiar una variable respuesta binaria y relacionarla con un conjunto de variables explicativas de naturaleza numérica y categórica. Su utilización permite estimar probabilidades y expresar los efectos de las variables mediante razones de momios u odds ratios, manteniendo constantes los demás predictores incluidos en el modelo.

Para organizar el análisis se empleó la metodología CRISP-DM, debido a que permite estructurar un proyecto de ciencia de datos desde la definición del problema hasta la evaluación de los resultados. De esta manera, el procedimiento no se limitó al ajuste de la regresión, sino que también incluyó la revisión de la información disponible, la limpieza y transformación de las variables, la separación de los datos, el diagnóstico del modelo y la evaluación de su capacidad de discriminación.

El objetivo del presente reporte es documentar la aplicación de CRISP-DM al conjunto de datos de la Evaluación Cognitiva de ENASEM 2021 y describir los resultados obtenidos mediante un modelo de regresión logística múltiple para la variable de depresión medida con CES-D.

Metodología

El estudio siguió un enfoque cuantitativo y observacional, utilizando información secundaria de la Evaluación Cognitiva de ENASEM 2021. La metodología de trabajo se organizó mediante CRISP-DM (Cross Industry Standard Process for Data Mining), cuyas fases permitieron establecer una secuencia desde la comprensión del objetivo analítico hasta la evaluación del modelo.

Comprensión del negocio

En esta primera fase se definió como problema de análisis la identificación de factores asociados con la presencia de síntomas de depresión en adultos mayores mexicanos, así mismo la variable dependiente fue *MC_CESD_DEPRIMIDO_21*, correspondiente a la depresión medida mediante la escala CES-D y recodificada en dos categorías: 0, no presenta síntomas de depresión, y 1, sí presenta síntomas de depresión. A partir de esta definición, se planteó desarrollar un modelo estadístico que permitiera estimar la probabilidad de presentar síntomas de depresión, utilizando información demográfica, funcional, cognitiva y psicosocial.

El objetivo de esta fase fue establecer una definición clara del problema y los criterios para evaluar el desempeño del modelo. Además del ajuste estadístico, se consideró su capacidad para discriminar entre las personas con y sin síntomas de depresión mediante el área bajo la curva ROC (AUC), como medida de evaluación de su capacidad predictiva.

Comprensión de los datos

El conjunto de datos utilizado corresponde a ECENASEM 2021 (Evaluación Cognitiva, ENASEM). La base inicial contenía 3,575 registros y, para este análisis, se seleccionaron 12 variables: edad, sexo, cuatro indicadores de actividades instrumentales de la vida diaria, percepción de memoria, tres variables relacionadas con aislamiento y compañía, nivel de estrés y la variable de depresión.

Grupo	Variables consideradas
Base	Edad; Sexo
Funcionalidad (AIVD)	Preparar comidas; Ir de compras; Tomar medicinas; Manejar dinero
Percepción cognitiva	Percepción de memoria
Aislamiento	Se siente aislado; Se siente ignorado; Le falta compañía
Estrés	Nivel de estrés percibido
Respuesta	Depresión (CES-D)

En la inspección inicial, las 12 variables aparecieron como objetos debido a la forma en que se leyó el archivo. Posteriormente se revisó su estructura y se identificó que la edad podía tratarse como variable numérica, mientras que las demás variables requerían una codificación categórica acorde con sus niveles. Esta revisión permitió establecer las transformaciones necesarias para el modelado.

Preparación de los datos

La preparación comenzó con la selección de las variables definidas en la etapa anterior. Los espacios en blanco y valores equivalentes a datos faltantes fueron transformados a valores NA. Posteriormente, la edad se convirtió a formato numérico; el sexo se codificó como Hombre y Mujer; las variables de AIVD se transformaron en categorías No y Sí; y las variables de percepción de memoria, aislamiento, compañía y estrés se mantuvieron como variables categóricas ordenadas.

Después de esta limpieza se realizó una eliminación por casos completos. De los 3,575 registros originales se conservaron 3,418, por lo que se eliminaron 157 observaciones. El porcentaje de registros excluidos fue de 4.39%. En los datos completos, 2,090 casos correspondieron a la categoría No de depresión (61.15%) y 1,328 a la categoría Sí (38.85%).

Etapa	Registros	Resultado
Datos originales	3,575	Conjunto inicial
Datos completos	3,418	Sin valores faltantes
Registros eliminados	157	4.39% del conjunto original
Depresión: No	2,090	61.15%
Depresión: Sí	1,328	38.85%

Debido a que el análisis parte de una sola fuente de datos, no fue necesario realizar una integración con otra base. Finalmente, la variable respuesta se transformó en una variable binaria y se generó la variable y, donde 0 representa No y 1 representa Sí. Los datos completos se dividieron mediante muestreo estratificado, conservando la proporción de la respuesta, en 70% para entrenamiento y 30% para prueba.

Conjunto	Observaciones	Proporción
Entrenamiento	2,392	70%
Prueba	1,026	30%
Total	3,418	100%

Modelado

Para el modelado se utilizó una regresión logística múltiple mediante un Modelo Lineal Generalizado con familia binomial y función de enlace logit. La especificación incluyó edad, sexo, los cuatro indicadores de AIVD, percepción de memoria, las tres variables de aislamiento y compañía y los cuatro niveles considerados para el estrés. El modelo se ajustó únicamente con el conjunto de entrenamiento, utilizando el método IRLS implementado en statsmodels.

El modelo final contó con 20 grados de libertad asociados a los predictores, 2,392 observaciones y un pseudo R^2 de Cox-Snell de 0.2606. Para facilitar la interpretación, los coeficientes del modelo se transformaron mediante la función exponencial para obtener odds ratios e intervalos de confianza al 95%.

Evaluación

La evaluación consideró diferentes aspectos del ajuste. En primer lugar, se revisó la multicolinealidad mediante el factor de inflación de la varianza (VIF). Después se aplicó la prueba de Hosmer-Lemeshow para valorar la correspondencia entre probabilidades observadas y esperadas. También se revisaron observaciones potencialmente influyentes mediante la distancia de Cook. Finalmente, el desempeño sobre datos no utilizados durante el ajuste se evaluó mediante la curva ROC y su área bajo la curva.

Criterio	Resultado	Interpretación en el análisis
Pseudo R^2 de Cox-Snell	0.2606	Medida global de ajuste del modelo
Hosmer-Lemeshow	$\chi^2 = 10.7179$; $p = 0.2182$	No se detecta evidencia de falta de ajuste con $\alpha = 0.05$
VIF máximo	8.67	Corresponde a percepción de memoria: nivel 2
VIF adicional alto	8.66	Corresponde a percepción de memoria: nivel 3
AUC en prueba	0.8329	Capacidad de discriminación del modelo

Resultados

Análisis exploratorio

Como parte de la exploración inicial se analizaron la distribución de la edad y la proporción de depresión según distintas variables categóricas. La edad presentó una media de 72.17 años, una desviación estándar de 7.46, una mediana de 72 años y un intervalo observado entre 58 y 99 años.

Estadístico	Edad
n	3,418
Media	72.17
Desviación estándar	7.46
Mínimo	58
Q1	66
Mediana	72
Q3	77
Máximo	99

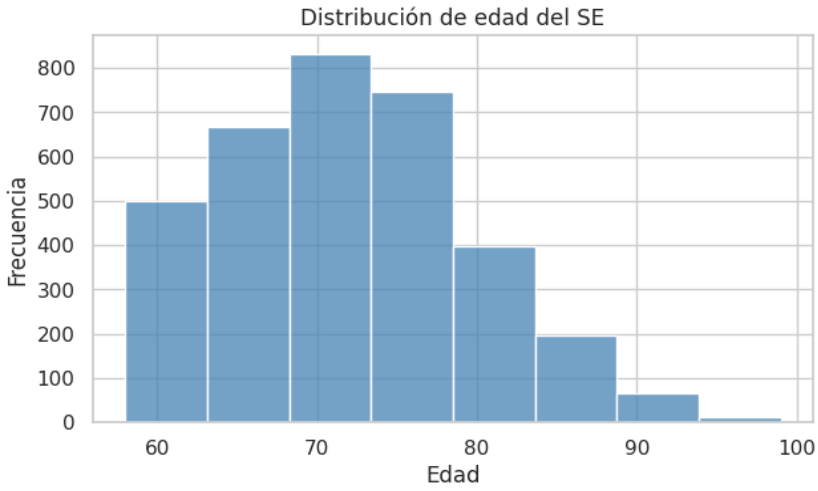


Figura 1 Distribución de la edad de los sujetos estudiados.

La distribución de la edad muestra una concentración de observaciones alrededor de los 66 a 77 años, con menor frecuencia hacia edades más avanzadas. Asimismo, el diagrama de caja permite observar que las edades de los grupos con y sin depresión presentan una distribución parcialmente superpuesta, por lo que la edad por sí sola no permite distinguir claramente ambas categorías.

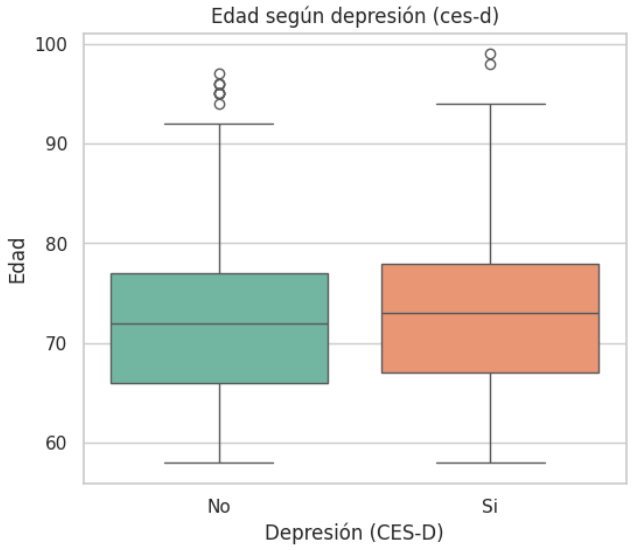


Figura 2 Edad según la categoría de depresión (CES-D).

En las variables categóricas se observaron diferencias en la proporción de depresión entre sus categorías. Por ejemplo, la gráfica correspondiente al sexo muestra una proporción de depresión mayor en mujeres que en hombres. En las variables relacionadas con funcionalidad, aislamiento, compañía y estrés también se observan cambios en la proporción de casos con depresión conforme cambian sus categorías.

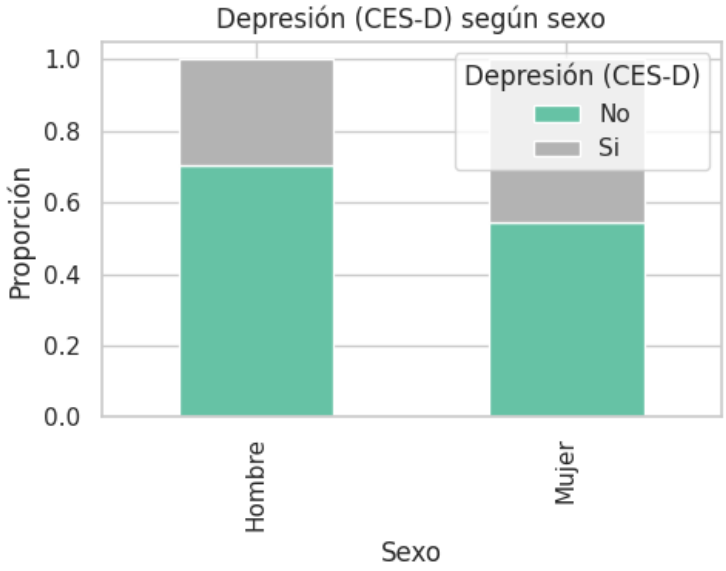


Figura 3 Proporción de depresión según sexo.

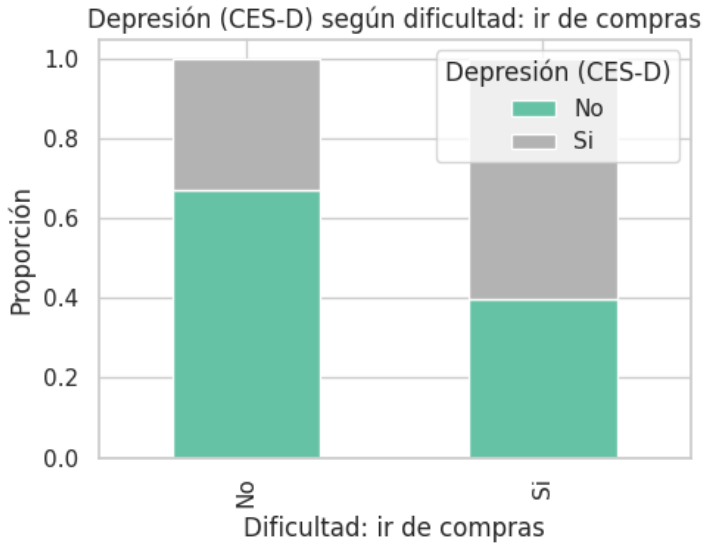


Figura 4 Proporción de depresión según dificultad para ir de compras.

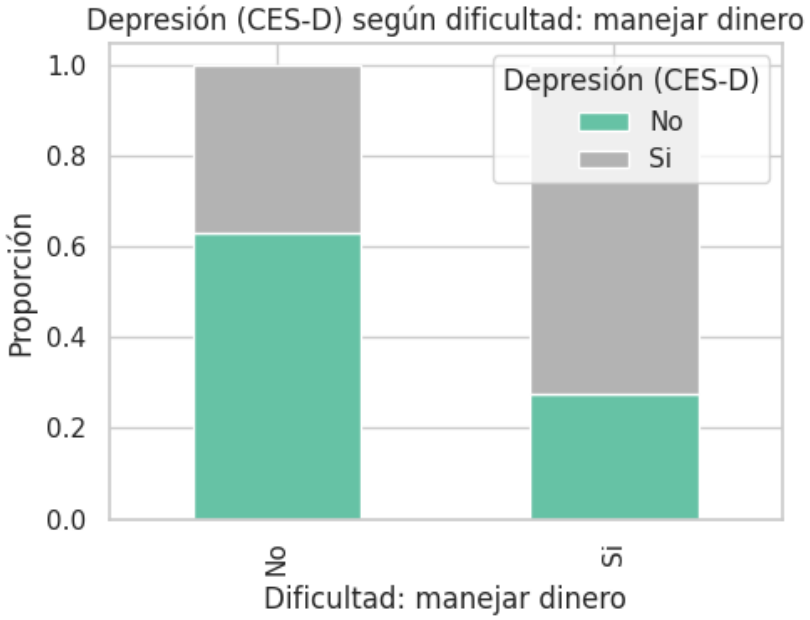


Figura 5 Proporción de depresión según dificultad para manejar dinero.

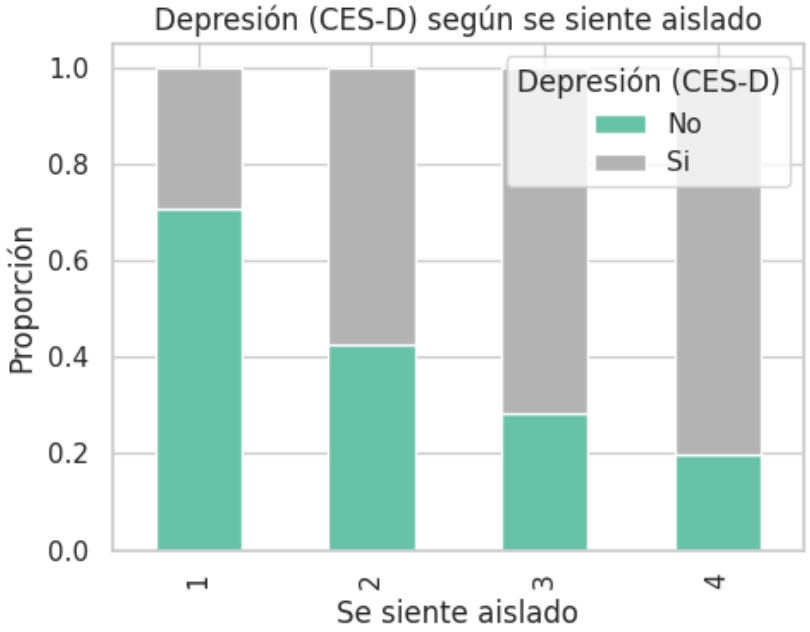


Figura 6 Proporción de depresión según percepción de aislamiento.

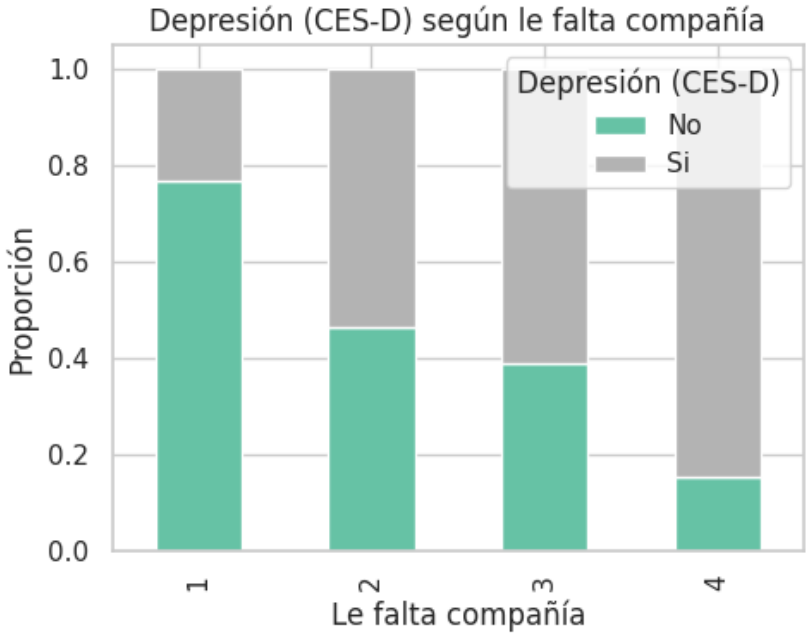


Figura 7 Proporción de depresión según falta de compañía.

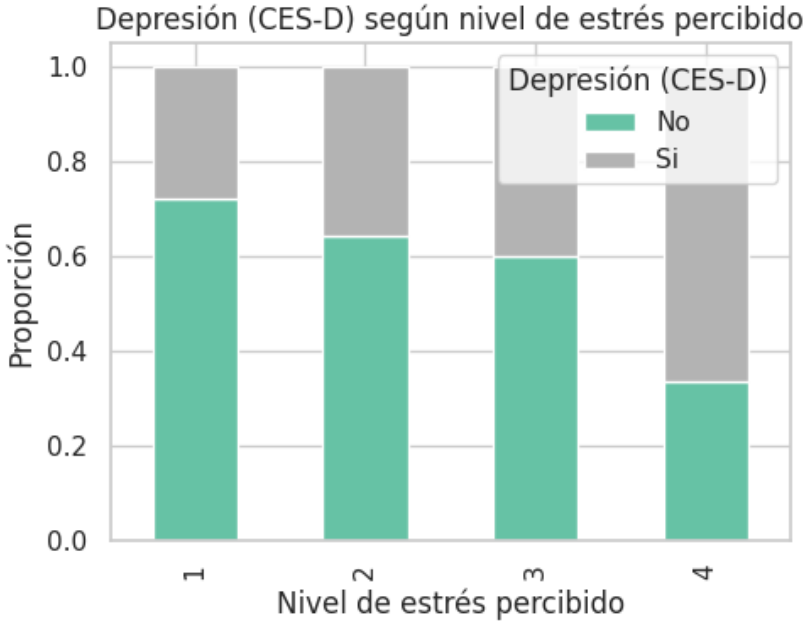


Figura 8 Proporción de depresión según nivel de estrés percibido.

.

Análisis del modelo de regresión logística

El modelo estimado permitió identificar las variables que presentaron evidencia estadística de asociación con la respuesta después de considerar simultáneamente el resto de los predictores. La siguiente tabla resume los odds ratios obtenidos para las categorías del modelo.

Variable	OR	IC 95%	p
Sexo: Mujer	1.295	1.057–1.586	0.013
Dificultad: preparar comidas: Sí	1.335	0.934–1.907	0.113
Dificultad: ir de compras: Sí	1.616	1.234–2.116	<0.001
Dificultad: tomar medicinas: Sí	1.417	0.930–2.161	0.105
Dificultad: manejar dinero: Sí	1.847	1.150–2.966	0.011
Percepción de memoria: 2	0.505	0.291–0.876	0.015
Percepción de memoria: 3	1.128	0.648–1.966	0.670
Se siente aislado: 2	1.065	0.777–1.461	0.695
Se siente aislado: 3	1.945	1.231–3.072	0.004
Se siente aislado: 4	0.831	0.419–1.648	0.597
Se siente ignorado: 2	1.916	1.413–2.598	<0.001
Se siente ignorado: 3	2.233	1.537–3.245	<0.001
Se siente ignorado: 4	2.655	1.259–5.601	0.010
Le falta compañía: 2	2.371	1.829–3.075	<0.001
Le falta compañía: 3	2.636	1.961–3.542	<0.001
Le falta compañía: 4	7.449	4.535–12.234	<0.001
Nivel de estrés percibido: 2	1.066	0.829–1.370	0.621

Nivel de estrés percibido: 3	1.318	1.002–1.732	0.048
Nivel de estrés percibido: 4	3.018	2.237–4.072	<0.001
Edad	1.010	0.996–1.024	0.159

Como se observa en la tabla, algunas variables presentaron asociaciones estadísticamente significativas al nivel de 0.05. En particular, el sexo de la categoría Mujer presentó un OR de 1.295 respecto de la categoría de referencia. Para las AIVD, la dificultad para ir de compras presentó un OR de 1.616 y la dificultad para manejar dinero un OR de 1.847. En ambos casos los intervalos de confianza no incluyeron el valor 1 y los p-valores fueron menores a 0.05.

En las variables relacionadas con aislamiento, la categoría 3 de sentirse aislado presentó un OR de 1.945. Para sentirse ignorado, los OR fueron 1.916, 2.233 y 2.655 en las categorías 2, 3 y 4, respectivamente. De manera similar, la falta de compañía presentó OR de 2.371, 2.636 y 7.449 para las categorías 2, 3 y 4. Estos resultados indican que, dentro de la parametrización utilizada, las diferencias entre estas categorías y sus respectivas categorías de referencia se reflejan en cambios en los momios estimados de la respuesta.

Respecto al estrés percibido, la categoría 3 presentó un OR de 1.318 con $p = 0.048$, mientras que la categoría 4 presentó un OR de 3.018 con $p < 0.001$. Por otra parte, la edad presentó un OR de 1.010, pero su p-valor fue 0.159, por lo que no se obtuvo evidencia estadística suficiente al nivel de 0.05 para establecer una asociación en este modelo.

Diagnóstico del modelo

El diagnóstico de multicolinealidad mostró que la mayoría de los predictores presentaron VIF bajos; sin embargo, las categorías 2 y 3 de percepción de memoria presentaron valores de 8.67 y 8.66, respectivamente. Estos valores son los más altos del modelo y deben considerarse al interpretar los coeficientes de dichas categorías.

Variable	VIF
Edad	1.10
Sexo: Mujer	1.08

Dificultad: preparar comidas: Sí	1.42
Dificultad: ir de compras: Sí	1.46
Dificultad: tomar medicinas: Sí	1.21
Dificultad: manejar dinero: Sí	1.25
Percepción de memoria: 2	8.67
Percepción de memoria: 3	8.66
Se siente aislado: 2	1.59
Se siente aislado: 3	1.40
Se siente aislado: 4	2.10
Se siente ignorado: 2	1.49
Se siente ignorado: 3	1.45
Se siente ignorado: 4	2.02
Le falta compañía: 2	1.33
Le falta compañía: 3	1.24
Le falta compañía: 4	1.50
Estrés: 2	1.29
Estrés: 3	1.27
Estrés: 4	1.37

La prueba de Hosmer-Lemeshow obtuvo un estadístico de 10.7179 y un p-valor de 0.2182. Debido a que el p-valor es superior a 0.05, no se encontró evidencia estadística de falta de ajuste bajo esta prueba.

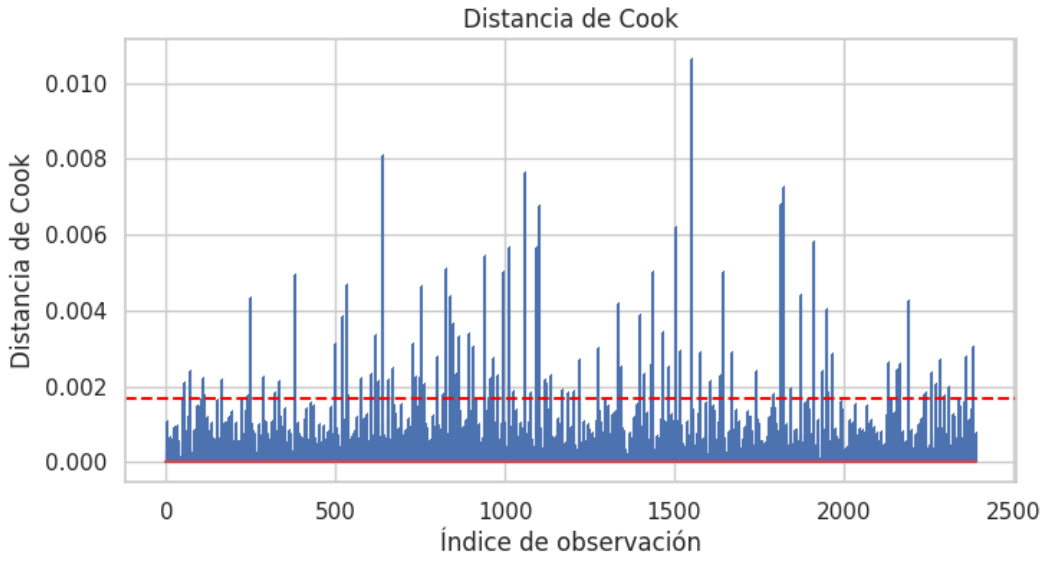


Figura 9 Distancia de Cook para la identificación de observaciones influyentes.

Evaluación sobre el conjunto de prueba

La evaluación fuera de muestra se realizó sobre las 1,026 observaciones del conjunto de prueba. El área bajo la curva ROC fue de 0.8329, lo que resume la capacidad del modelo para discriminar entre las dos categorías de la variable respuesta. La curva ROC se construyó a partir de las probabilidades estimadas por el modelo y de los diferentes puntos de corte.

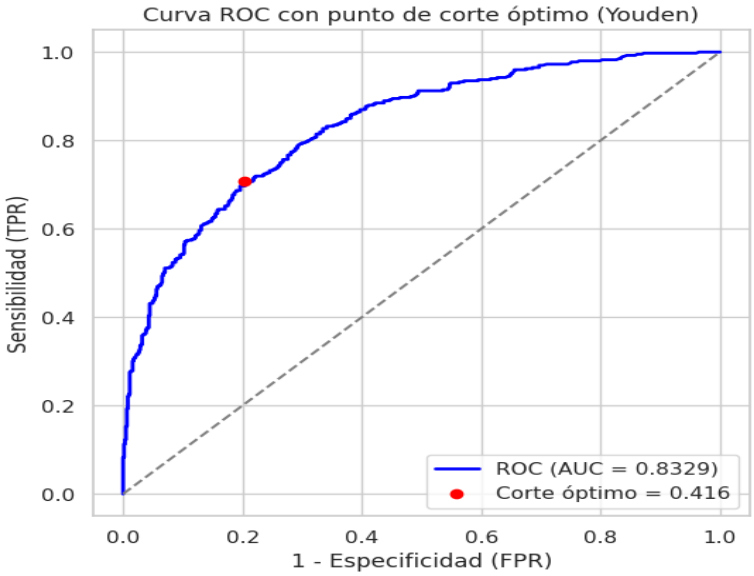


Figura 10 Curva ROC del modelo de regresión logística en el conjunto de prueba (AUC = 0.8329).

Conclusiones

La aplicación de la metodología CRISP-DM permitió desarrollar de manera ordenada un modelo de regresión logística múltiple utilizando información de ECENASEM 2021. El proceso comenzó con la definición de la depresión como variable respuesta y continuó con la revisión, limpieza, transformación y partición de los datos antes de realizar el modelado.

A partir de los 3,575 registros iniciales se obtuvieron 3,418 casos completos, eliminando el 4.39% de las observaciones por presencia de valores faltantes. El conjunto final presentó 2,090 casos sin depresión y 1,328 con depresión. La partición estratificada permitió disponer de 2,392 observaciones para entrenamiento y 1,026 para prueba.

El modelo de regresión logística mostró asociaciones estadísticamente significativas para diferentes categorías de sexo, funcionalidad, aislamiento, sentirse ignorado, falta de compañía y estrés. Entre los valores observados destacan los OR de 7.449 para la categoría 4 de falta de compañía y 3.018 para la categoría 4 de estrés percibido, siempre interpretados respecto de sus categorías de referencia.

Finalmente, la evaluación mostró un p-valor de 0.2182 en Hosmer-Lemeshow y un AUC de 0.8329 en el conjunto de prueba. Estos resultados aportan evidencia de un ajuste compatible con los datos y de una capacidad de discriminación útil dentro del conjunto evaluado. Al mismo tiempo, los VIF de 8.67 y 8.66 para percepción de memoria muestran que existe un aspecto de multicolinealidad que debe ser considerado.

Referencias

Agresti, A. (2019). *An introduction to categorical data analysis* (3rd ed.). John Wiley & Sons.

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS.

Google. (2026). *Google Colaboratory* [Cuaderno de código]. https://colab.research.google.com/drive/124v2OYOi3IE6n0aeLY0xW0GU0ZSp9I5R#scrollTo=AkhHHzhDHkVu

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied logistic regression* (3rd ed.). Wiley. https://doi.org/10.1002/9781118548387

Instituto Nacional de Estadística y Geografía. (2021). *Datos abiertos*. https://www.inegi.org.mx/datosabiertos/

McCullagh, P., & Nelder, J. A. (1989). *Generalized linear models* (2nd ed.). Chapman & Hall.

Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with Python. En *Proceedings of the 9th Python in Science Conference* (pp. 57–61).